بيانات التقييم والمقاييس

شو البيانات يلي رح نقيس عليها من الأوراق البحثية، وشو منقيس على كل وحدة، وكيف

التاريخ: 28-10-2026 المشروع: Senior-project1ATDG / Ai_project مكان البيانات: `evaluation/external/`

52	885	1991	—
DocPrism المعنونة (Python)	CASCADE (Java)، منهم 71 تناقض	DocPrism الكبيرة (4 لغات، بدون وسم)	Code vs Code: بانتظار البيانات

المحتويات

1. المبادئ: ليش هيك ومنقيس متى
2. نظرة عامة على كل البيانات
3. DocPrism المعنونة (ablation): 52 دالة
4. CASCADE: 885 دالة جافا
5. DocPrism الكبيرة: 1991 دالة
6. بيانات Code vs Code
7. تعريف المقاييس
8. تحويل البيانات لشكل نظامنا
9. قواعد العدالة بالقياس
10. الميزانية: عدد الطلبات
11. القرارات المعلّقة

1. المبادئ: ليش هيك ومنقيس متى

- **كل البيانات من الأوراق البحثية نفسها**: DocPrism و CASCADE لمسار Code vs Doc، و AexPy و NPM لمسار Code vs Code. مجموعة التطوير يلي كتبناها قبل ما عاد منستعملها بالتقارير.
- **منقيس بعد كل خطوة**، مش بالآخر بس، لحتى نشوف مدى التحسين خطوة بخطوة.
- **النسختين بيشوفوا نفس المدخل بالزبط**: القديمة المجمّدة (`legacy_baseline`) والحالية (`core_ai`).
- **ممنوع نفصّل النظام على بيانات القياس.** لهيك في مجموعة منسمح لحالنا نفتح أخطاءها ونتعلّم منها (DocPrism)، ومجموعة منشوف أرقامها بس (CASCADE). التفاصيل بالقسم 9.

2. نظرة عامة على كل البيانات

المجموعة	اللغة	الحجم	الوسم	الدور	منقيس متى	طلبات LLM / قياس
DocPrism ablation	Python	52	✅ متوافق / متناقض	تطوير: **منفتح الأخطاء**	بعد كل خطوة	52
CASCADE المتوازنة	Java	142 (71+71)	✅	تقرير: **أرقام بس**	بعد كل خطوة	142
CASCADE الواقعية	Java	710 (71+639)	✅	تقرير: أرقام بس	بالمحطات المهمة	710

DocPrism الكبيرة	Py / TS / C++ / Java	1991	❌	بس Flag Rate	بالآخر (اختياري)	1991
AexPy-index	Python	يتحدد	⚠️ مخرجات أداة	Code vs Code (بنيوي)	بعد كل خطوة 7–11	حسب العدد
NPM (TOSEM 2025)	JS / TS	2724 تغيير	✅ بشري	Code vs Code (بنيوي + سلوكي)	بعد الموافقة	حسب العدد

النسخة القديمة من Code vs Doc ما بتستعمل LLM، فقياسها ببلاش. طلبات الـ LLM بالجدول هي للنسخة الحالية، بعد ما يدخل الـ LLM بالخطوة 5.

3. DocPrism المعنونة (ablation): 52 دالة

3.1 المصدر

- **الورقة:** DocPrism (Xu وآخرين، arXiv 2511.00215). الأداة بتكشف التناقض بين الكود والتوثيق بمنهجية LCEF.
- **الملفات:** `datasets/ablation_dataset/pandas_labeled.json` و `requests_labeled.json` بمستودع `SnowPhoebe/DocPrism`، رخصة MIT.
- **شو هي:** المجموعة يلي استعملوها بدراسة الـ ablation بالورقة، يعني الجزء المعنون بالكامل من مجموعة البناء تبعهم. الوسم عملوه شخصين من المؤلفين، كل واحد لحاله، وحسموا الخلافات بالنقاش.

3.2 المحتوى

المشروع	الدوال	متناقضة	متوافقة
pandas	21	3	18
Requests	31	3	28
المجموع	**52**	**6**	**46**

الدوال المتناقضة الست: `is_monotonic_increasing` و `_preparse` و `set_test_mode` و `mount` و `put` و `patch`.

شكل كل حالة: `{"id", "doc", "code", "label"}`. الـ `doc` هو الـ docstring، والـ `code` هو الدالة كاملة، والـ `label` قيمته `consistent` أو `inconsistent`. الوسم **ثنائي بس**، ما فيه تصنيف Direct أو Over.

ملاحظة: 26 من الـ 52 دالة مستقلة، يعني مش جوا كلاس. القسم 8 بيشرح ليش هالشي مهم.

3.3 دورها: مجموعة التطوير

هي المجموعة الوحيدة يلي **منسمح لحالنا نفتح الحالات يلي غلط فيها النظام** ونفهم ليش، ومنستعمل هالشي لنحسّن. وهالشي متل يلي عمله مؤلفين DocPrism نفسهم بمجموعة البناء.

3.4 المقاييس

المقياس	ليش
Precision	من التنبيهات، قديش صح. هاد الأهم لتجربة المطوّر
Recall	من الست المتناقضة، قديش لقى
F1	توازن بين الاثنين
Specificity	من الـ 46 المتوافقة، قديش تركها بحالها
Flag Rate	نسبة الدوال يلي نبّه عليها. الورقة بتقيس هاد

تنبيه بالتفسير

في **6 حالات متناقضة بس**، فكل حالة بتساوي 16.7% من الـ Recall. يعني تغيير حالة وحدة بيحرّك الرقم كتير. لهيك منكتب دايماً العدد مع النسبة، متل `Recall = 0.50 (3/6)`.

4. CASCADE: 885 دالة جافا

4.1 المصدر

- **الورقة:** CASCADE (Kiecker وآخرين، arXiv 2604.19400، DOI 10.1145/3808175، FSE 2026).
- **الملف:** `PaperEvaluation/dataset.zip` بمستودع `TobiasKiecker/CASCADE`، فرع `FSE26`، حجمه 15 ميغا.
- **كيف انبنت:** من commits بمشاريع جافا كبيرة **صلّحت التوثيق**، يعني المطوّر نفسه اعترف إنه التوثيق كان غلط. انتقوا مشاريع بتشتغل وبتنبنى، وتأكدوا يدوياً من كل تناقض.

4.2 المحتوى حسب المشروع

المشروع	متوافقة	متناقضة	المشروع	متوافقة	متناقضة
commons-lang	186	10	commons-codec	29	3
commons-math	176	13	commons-collections	27	2
jsoup	114	8	guava	26	2
joda-time	88	8	jackson-core	25	2
commons-cli	44	4	jfreechart	20	1
gson	30	3	jackson-databind	18	2
commons-csv	14	4	commons-compress	12	3
jsprit	3	3	assertj	3	2

هالأرقام حسب ملفات `.txt` كما هي: 815 متوافقة و 70 متناقضة. بعد التصحيح بالقسم 4.4 بيصيروا 814 و 71 (commons-codec بتصير 28 و 4).

4.3 شكل البيانات

الملف	المحتوى
`<project>/<commit>/<n>/analyzed.json`	الدالة: `code` (الجسم)، و `doc` (Javadoc)، و `signature` (الاسم، والإرجاع، والمعاملات، والـ modifiers، والاستثناءات)، و `parent` (اسم الكلاس، وتوثيقه، والـ constructors، والحقول، وباقي الدوال)، و `package`
`.../inconsistency.txt`	`True` = متناقضة، `False` = متوافقة
`dataset_mapping_dict.py`	بيربط كل حالة متناقضة بنسختها المصلّحة (71 زوج)

`dataset_info.xlsx`	142 سطر (71 متناقضة + 71 مصلّحة)، مع ملاحظة المؤلفين عن نوع كل تصليح

أمثلة من ملاحظات المؤلفين عن أنواع التناقض: نوع الاستثناء تغيّر، والتوثيق بيقول "returns null" والكود بيرمي استثناء، وإشارة `>` مكان `=>`، والتوثيق بيقول "returns empty list" والكود بيرجّع null، ونسخ ولصق غلط بالوصف، وترميز مختلف عن المذكور.

4.4 فرق لقيناه بالبيانات

70 مقابل 71

ملفات `.txt` فيها 70 `True`، بينما الورقة وملف الربط والجدول فيهم 71. السبب حالة وحدة (`commons-codec/6175c99…/1`) ملف `.txt` تبعها مكتوب فيه `False` بالغلط، مع إنها بملف الربط حالة متناقضة وبالجدول `True`. **القرار: منعتمد ملف الربط والجدول (71)**، ومنذكر هالشي بالتقرير.

كل التصليحات كانت بالتوثيق بس

بالـ 71 زوج، الكود نفسه ما تغيّر بين النسخة المتناقضة والمصلّحة. فـ CASCADE بتنفع لـ Code vs Doc بس، **مش** لـ Code vs Code.

4.5 المجموعات الفرعية

المجموعة	التكوين	شو بتقيس	متى
المتوازنة (142)	71 متناقضة + نسختهم المصلّحة (71)	القدرة على التمييز، و PFP	بعد كل خطوة
الواقعية (710)	71 متناقضة + 639 متوافقة منختارهم عشوائياً (seed ثابت = 42) من الـ 743. يعني 10% متناقضة	الأداء بتوزيع قريب من الواقع	بالمحطات المهمة
الكاملة (885)	كل شي	للمرجع	اختياري

الـ 743 المتوافقة الإضافية: الورقة نفسها بتقول إنها "متوافقة بشكل تقريبي"، لأنها دوال ما انلمس توثيقها، مش دوال حدا تأكد منها يدوياً. لهيك رقم الـ Specificity عليها تقريبي.

4.6 المقاييس

المقياس	ليش
Precision / Recall / F1	الأساسية، وبتنقارن مع أرقام الورقة
Specificity	من المتوافقة، قديش تركها. الأقرب لتجربة المطوّر اليومية
PFP (Pair-wise Fix Precision)	من الحالات يلي كشفها النظام صح، قديش منهم **صنّف نسختهم المصلّحة إنها سليمة**؟ إذا نبّه على النسختين، معناها عم يلقط شي سطحي مش التناقض نفسه
Flag Rate	نسبة التنبيهات

4.7 الأرقام المنشورة للمقارنة (على المجموعة المتوازنة)

الأداة	Precision	Specificity	Recall
CASCADE	0.88	0.97	0.21
LLM-A (سؤال مباشر)	0.59–0.55	0.81–0.64	0.46–0.29
LLM-S (سؤال بسيط)	0.56–0.53	0.58–0.42	0.67–0.54
C4RLLaMA	0.53–0.45	0.64–0.63	0.41–0.31
DocChecker	0.49–0.48	0.19–0.03	0.96–0.77

المصدر: خطة الإثبات تبعكم، يلي نقلت أرقام ورقة CASCADE. نظامنا معتمد على prompt للـ LLM، فأقرب شي إله هو LLM-A و LLM-S.
الهدف: Recall أعلى من CASCADE، مع Precision بمستوى خطوط LLM أو أعلى.

4.8 دورها: أرقام بس

منقيس عليها بعد كل خطوة ومنشوف الأرقام، بس ما منفتح الحالات يلي غلط فيها لنعدّل النظام عليها. هيك بتضل الأرقام دليل صادق.

5. DocPrism الكبيرة: 1991 دالة

اللغة	العدد	المشاريع (100 دالة لكل مشروع تقريباً)	متوسط طول الكود
Python	500	django، flask، matplotlib، nltk، scrapy	8 أسطر
TypeScript	494	hoppscotch، n8n، nest (94)، puppeteer، socket.io	8 أسطر
C++	497	bitcoin، godot، llama.cpp (97)، tesseract، x64dbg	16 سطر
Java	500	cassandra، hadoop، kafka، spark، zeppelin	7 أسطر

- **الشكل:** `{"id", "filename", "doc", "code"}` ، وكل مشروع مثبّت على commit محدد.
- **ما فيها وسم.** المؤلفين فحصوا يدوياً بس الحالات يلي نبّهت عليها أداتهم، فما بينحسب عليها Recall.
- **المقاييس:** Flag Rate بس. واختيارياً، منفحص يدوياً عينة من تنبيهات نظامنا ومنقدّر الـ Precision.
- **للمقارنة:** الورقة بتقول Flag Rate حوالي 15–17%، و Precision حوالي 0.62–0.64. الأرقام بتختلف شوي بين نسخ الورقة.
- **متى:** بالآخر، لأنها كبيرة (1991 طلب).
- 137 من 500 دالة بايثون مستقلة (برّا كلاس).

6. بيانات Code vs Code

الوضع الحالي

ولا ورقة من الثلاث نشرت بيانات جاهزة موسومة يدوياً على مستوى الدالة (قبل وبعد).

المصدر	شو متاح	بينفع لـ	الحالة
AexPy (ISSRE 2022)	الورقة اختبرت على 61 تغيير معروف بس ما نشرتهم كملف. متاح: الأداة، و `aexpy-index` فيه نتائجها على نسخ حقيقية من مكتبات بايثون	Q1 (الواجهة) و Q3 (بيكسر)، بس التغييرات الهيكلية	مرجع مؤقت (مخرجات أداة، دقتها حسب الورقة 93.5%)
NPM (TOSEM 2025)	2724 تغيير موثّق من 381 مشروع، مع تصنيف للتغييرات الهيكلية والسلوكية	Q1 و Q2 و Q3، و**التغييرات السلوكية**	**مقفلة** على Zenodo، لازم طلب من المؤلفين
Safer Builders (MSR 2026)	PRs من مجموعة AIDev، والتصنيف من أداتهم	مقارنة عامة	الوسم من أداة، مش بشري

المقاييس المخططة

- **مع AexPy:** Precision و Recall و F1 للتغييرات الهيكلية و "بيكسر"، مقارنةً بمخرجات AexPy على نفس النسختين.
- **مع NPM:** Recall لكل نوع تغيير بالتصنيف، وخاصة السلوكي. ونسبة التنبيهات الغلط.
- **لكل القياسات:** عدد استدعاءات الـ LLM لكل عينة. الخطوة 11 هدفها تقليلهم.

7. تعريف المقاييس

الرمز	المعنى
TP	نبّه، وفعلاً في تناقض
FP	نبّه، وما في تناقض (إنذار كاذب)
FN	ما نبّه، وفي تناقض (فاته)
TN	ما نبّه، وما في تناقض

المقياس	المعادلة	السؤال يلي بيجاوبه
Precision	`TP / (TP + FP)`	من التنبيهات، قديش صح؟
Recall	`TP / (TP + FN)`	من التناقضات الحقيقية، قديش لقى؟
F1	`2·P·R / (P + R)`	توازن بين الاثنين
Specificity	`TN / (TN + FP)`	من السليمة، قديش تركها؟
Flag Rate	`(TP + FP) / N`	قديش بيزعج المطوّر؟
PFP	من الحالات يلي كشفها صح، نسبة يلي صنّف نسختها المصلّحة سليمة	عم يلقط التناقض الحقيقي أو شي سطحي؟

متى منعتبر النظام "نبّه"؟ إذا طلّع أي تنبيه على هالدالة، ما عدا الإحصائيات العامة و "دالة غير موثّقة". هيدا الأخير بيصير تغطية من الخطوة 6. وبعد الخطوة 5، إذا النظام صنّف التنبيه `Under_Promise` ، ما بينحسب تنبيه، لأنه حسب DocPrism ما بيتعرض للمستخدم.

كيف منكتب الأرقام: لكل مقياس منكتب النسبة والعدد مع بعض، متل `0.50 (3/6)`، وعدد الطلبات، وعدد العينات يلي فشل فيها الـ LLM.

8. تحويل البيانات لشكل نظامنا

كل حالة بالبيانات هي دالة لحالها مع توثيقها. ونظامنا بيستقبل **ملف كود** و**توثيق بشكل Markdown** (متل يلي بيولّده). فمنكتب محوّل:

البيانات	الكود	التوثيق
CASCADE (Java)	منعيد بناء الكلاس من `parent` و `signature` و `code`	بيصير `## Class: X` ← `### Method: name` ← نص التوثيق. هاد نفس الشكل يلي بيستعمله `run_baseline` للـ docstrings
DocPrism (Python)	الدالة متل ما هي. إذا فيها `self` ، منحطها جوا كلاس	

مشكلة بالنظام: الدوال المستقلة

معالج بايثون **بيقرأ بس الدوال يلي جوا كلاس**. أي دالة على مستوى الملف ما بتظهر، فالنظام ما بيقارنها أبداً، لا بالتوثيق ولا بنسختها القديمة. نسبتها **26 من 52** بـ DocPrism المعنونة، و **137 من 500** بـ DocPrism الكبيرة. هاد خلل بالمنتج نفسه. منقيسها متل ما هي، لحتى **تبيّن المشكلة بالأرقام**، وإصلاحها مقترح كخطوة بالخطة.

9. قواعد العدالة بالقياس

1. **نفس المدخل للنسختين:** نفس المحوّل، ونفس التوثيق، ونفس الكود.
2. **LLM حتمي:** موديل مثبّت (`poolside/laguna-s-2.1:free`)، و temperature 0، و seed 42، وبدون cache، وبدون fallback لموديل تاني. وكل رد بينسجّل.
3. **النسخة القديمة مجمّدة:** بتنقاس مرة وحدة وبتنحفظ النتيجة، وبصمتها بتنسجّل مع كل قياس.
4. **DocPrism المعنونة:** مسموح نفتح الأخطاء ونتعلّم منها.
5. **CASCADE:** منشوف الأرقام بس، وما منعدّل النظام على حالات محددة منها. وما منحط أي مثال منها بالـ prompt.
6. **أي فرق أو خلل بالبيانات منوثّقه**، متل فرق 70 مقابل 71.

10. الميزانية: عدد الطلبات

حسابكم على OpenRouter مجاني. والحد حسب توثيق OpenRouter:

الحالة	طلب / دقيقة	طلب / يوم
بدون شحن (الحالي)	20	**50**
بعد شحن $10 مرة وحدة	20	**1000**

القياس	الطلبات	بدون شحن	مع شحن
بعد كل خطوة (DocPrism 52 + CASCADE 142)	194	4 أيام	نفس اليوم
محطة (CASCADE الواقعية)	710	15 يوم	نفس اليوم
بالآخر (DocPrism الكبيرة)	1991	40 يوم	يومين

الموديلات المجانية بتضل مجانية بعد الشحن، والـ $10 بتضل رصيد بالحساب. والنسخة القديمة من Code vs Doc ما بتستعمل LLM، فما بتحسب من الحد.

11. القرارات المعلّقة

#	القرار	اقتراحنا
1	تقسيم الأدوار: DocPrism منفتح أخطاءها، و CASCADE أرقام بس	نعم
2	شحن حساب OpenRouter $10	نعم، وإلا منقيس على عينة أصغر
3	طلب بيانات NPM من المؤلفين (من حساب Zenodo لواحد منكم)	نعم، وبنكتب نص الطلب
4	AexPy-index كمرجع مؤقت لـ Code vs Code	نعم، مع ذكر إنه مخرجات أداة
5	إصلاح الدوال المستقلة كخطوة جديدة	نعم. وقتها حسب قراركم

المصادر

- DocPrism: arxiv.org/abs/2511.00215 — github.com/SnowPhoebe/DocPrism
- CASCADE: arxiv.org/abs/2604.19400 — github.com/TobiasKiecker/CASCADE (FSE2026-v1.0.0)
- AexPy: github.com/stardustdl/aexpy — github.com/StardustDL-Labs/aexpy-index
- NPM Breaking Changes: arxiv.org/abs/2408.14431 — zenodo.org/records/13219136
- Safer Builders: arxiv.org/abs/2603.27524
- OpenRouter limits: openrouter.ai/docs/api-reference/limits