تقرير التقدّم 3: بيانات الأوراق والتحليل الدلالي

شغل يوم 28-10-2026: بيانات الأوراق البحثية، الدوال المستقلة، والخطوات 4 و 5 و 6

التاريخ: 28-10-2026 يكمّل: progress_report_step3_evaluation.pdf آخر commit: `f9b2099`

97/97	5	4	0
اختبار ناجح (كانوا 44 الصبح)	مصادر بيانات من أوراق بحثية	خطوات منجزة اليوم (3ب، 4، 5، 6)	إنذارات كاذبة على CASCADE (بدون LLM)

المحتويات

1. ملخص اليوم
2. التحوّل لبيانات الأوراق البحثية
3. البيانات يلي نزّلناها
4. أول قياس على بيانات الأوراق
5. توجيه الدكتور: ورقة وحدة لكل قسم
6. الخطوة 3ب: الدوال المستقلة
7. الخطوة 4: تعليمات الذكاء الاصطناعي
8. الخطوة 5: الإرسال والقراءة والفلترة
9. الخطوة 6: الربط بالنظام
10. جدول التقدّم على CASCADE
11. مشاكل انكشفت اليوم
12. الحسابات والمفاتيح
13. سجل الـ commits والملفات
14. الخطوات الجاية

1. ملخص اليوم

الشغل	النتيجة
بيانات الأوراق البحثية	نزّلنا بيانات DocPrism و CASCADE و NPM و Safer Builders، وكتبنا محوّل لشكل نظامنا. وكشفنا إنه "نجاح" النظام القديم على CASCADE وهمي.
الخطوة 3ب	صار النظام يشوف الدوال يلي برّا الكلاسات (بايثون وجافاسكربت وتايبسكربت). نص بيانات DocPrism ما كان ينفحص.
الخطوة 4	تعليمات للذكاء الاصطناعي مبنية على تعليمات DocPrism المنشورة.
الخطوة 5	إرسال الطلب، وقراءة الجواب، والفلترة: نرمي يلي اخترعه الموديل، ونخفي الوعد الناقص.
الخطوة 6	ربط كل شي بالنظام. وشلنا مصادر الإنذارات الكاذبة القديمة، فصارت صفر على CASCADE.

2. التحوّل لبيانات الأوراق البحثية

الصبح كان عنا مجموعة تطوير كتبناها نحنا (66 عنصر). **القرار:** ما منستعملها بالتقارير، ومنقيس على **بيانات الأوراق البحثية نفسها** بعد كل خطوة.

قاعدة العدالة

إذا ضلّينا نعدّل النظام ونقيس على نفس الحالات، بيتفصّل النظام عليها وبتطلع الأرقام أحلى من الحقيقة. لهيك بكل مجموعة في **قسم منفتح أخطاءه** ونتعلّم منه، و**قسم منشوف أرقامه بس**.

3. البيانات يلي نزّلناها

المصدر	من وين	المحتوى	الوسم
DocPrism	GitHub (SnowPhoebe/DocPrism)، MIT. الرابط المجهول بالورقة كان منتهي	52 دالة بايثون موسومة (6 متناقضة)، و 1991 دالة بأربع لغات بدون وسم، وتعليمات الأداة المنشورة	بشري (شخصين)
CASCADE	GitHub (TobiasKiecker/CASCADE)، فرع FSE26، MIT	885 دالة جافا من 16 مشروع: 71 متناقضة مع نسختها المصلّحة، والباقي متوافق	بشري (متحقق يدوياً)
NPM	Zenodo 13857646 (النسخة v3 **مفتوحة**، CC BY 4.0). النسخة v4 مقفلة	1519 تغيير بيكسر الكود من 131 مشروع. منهم **1034 تغيير بالسلوك**، و 203 تغيير قيمة افتراضية	بشري
Safer Builders	figshare، CC BY 4.0	أداتهم (حوالي 8 قواعد، مش 17 متل ما بتقول الورقة)، و 110,047 تعديل ملف من PRs بشرية. ما فيها نتائج لكل تعديل، ولا الـ 94 حالة يلي فحصوها يدوياً	أداة
AexPy	GitHub، والأداة على PyPI	الـ 61 تغيير يلي بالورقة **مش منشورين**. متاح بس الأداة ونتائجها (aexpy-index)	أداة

ملاحظات على البيانات

- **CASCADE:** ملفات `.txt` فيها 70 تناقض، بينما الورقة وملف الربط والجدول فيهم 71. حالة وحدة (`commons-codec 6175c99`) ملفها مكتوب فيه `False` بالغلط. **اعتمدنا 71.**
- **CASCADE:** بكل الـ 71 تصليح، الكود ما تغيّر، بس التوثيق. فهي بتنفع للكود مقابل التوثيق بس.
- **DocPrism:** 7 من الـ 52 حالة كان فيها مسافات (indentation) مكسورة **من المصدر**، لأنه لما المؤلفين شالوا التوثيق من الكود ضل أثر. صلّحناهم ووثّقنا التصليح.
- **NPM:** الوسم لكل تعديل (commit)، مش لكل دالة، وكل الحالات تغييرات بتكسر الكود. فمنقيس فيها قديش النظام بيكشف من كل نوع.

تحويل البيانات لشكل نظامنا

- `build_paper_sets.py` : كل حالة بتصير ملف كود، وتوثيق بنفس شكل يلي بيولّده نظامنا (`## Class` و `### Method`). الجافا بيرجع ينبني منها الكلاس، والبايثون بيتحط جوا كلاس إذا كانت method.
- `fetch_npm_code.py` : بيجيب الكود قبل التعديل وبعده من GitHub لكل تعديل. وصل لـ 550 من 1487، وبيكمّل من مطرح ما وقف إذا انقطع.
- وثيقة منفصلة فيها شرح البيانات والمقاييس: `docs/evaluation_datasets_and_metrics.pdf` .

4. أول قياس على بيانات الأوراق

المجموعة	النظام	انكشف	إنذارات كاذبة	Precision	Specificity	PFP
CASCADE المتوازنة (142)	القديم	**49/71**	**49/71**	0.50	0.31	**0.00**
	الحالي	1/71	1/71	0.50	0.99	0.00
CASCADE الواقعية (710)	القديم	49/71	429	**0.10**	0.33	—
	الحالي	1/71	4	0.20	0.99	—
DocPrism (52)	القديم	0/6	1	—	0.98	—
	الحالي	0/6	2	—	0.96	—

"نجاح" النظام القديم على CASCADE وهمي

نبّه على 49 نسخة متناقضة، ونبّه على **نفس العدد بالزبط (49)** من النسخ المصلّحة. كل تنبيهاته كانت "Signature mismatch"، وسببها خطأ بقراءة توقيعات الجافا. يعني تنبيهاته ما إلها علاقة بالتناقض: **PFP = 0**. وبالتوزيع الواقعي، 9 من كل 10 تنبيهات منه غلط (Precision = 0.10). هاد بالزبط الشي يلي مقياس PFP معمول ليكشفه.

ومقابلها الأرقام المنشورة على CASCADE المتوازنة: CASCADE نفسها: Precision 0.88 و Recall 0.21. وسؤال الذكاء الاصطناعي مباشرة: Precision تقريباً 0.55 و Recall بين 0.29 و 0.67.

5. توجيه الدكتور: ورقة وحدة لكل قسم

القسم	الورقة	ليش هي الأقرب لشغلنا
الكود مقابل التوثيق	**CASCADE**	ورقتها بتقارن مباشرة مع "سؤال الذكاء الاصطناعي"، وهاد يلي بيعمله نظامنا. وفيها 71 تناقض مع نسخها المصلّحة، فمنقدر نقيس PFP. أما DocPrism ففيها 6 تناقضات بس.
الكود مقابل الكود	**NPM**	الوحيدة يلي وسمها بشري، وفيها التغييرات بالتوقيع والتغييرات بالسلوك.

تقسيم CASCADE

القسم	الحجم	الاستعمال
`cascade_dev`	25 زوج (50 حالة) من 15 مشروع	منفتح أخطاءه ومنحسّن عليه، ومنقيس عليه كل يوم
`cascade_test`	46 زوج (92 حالة) من 16 مشروع	أرقام بس، بالمحطات المهمة. **هاد الرقم النهائي للتقرير**

التقسيم بالأزواج الكاملة، يعني الحالة المتناقضة ونسختها المصلّحة بنفس القسم. وموزّع على المشاريع بنسبة حجمها، و seed = 42، وما في تداخل. والنظام القديم طلّع نتيجة متشابهة بالقسمين (0.68 و 0.70)، يعني التقسيم عادل.

6. الخطوة 3ب: الدوال المستقلة (برّا الكلاسات)

المشكلة: قارئ الملفات كان يشوف بس الدوال يلي جوا كلاس. نسبة الدوال المستقلة: **26 من 52** بـ DocPrism، و **185 دالة** بمشروعنا نفسه، و **58 دالة** بواجهة المشروع.

الحل:

- قارئ الملفات بيجمعهم بمفتاح منفصل (`module_functions`)، فمخطط الكلاسات بالواجهة ما بيتغيّر.
- النظام بيحطهم بكلاس وهمي اسمه `<module>` ، وما بيطلع عليه تنبيهات على مستوى الكلاس.
- بالجافاسكربت والتايبسكربت صار يقرأ: `function` ، و `export function` ، و `export default function` ، و `const f = () =>` .

الفحص	النتيجة
بايثون: 130 ملف من مشروعنا، قبل وبعد	الكلاسات والعلاقات متطابقة 130/130، وصار في 185 دالة مستقلة بتنشاف
تايبسكربت: 23 ملف من الواجهة	متطابق 23/23، وصار في 58 دالة مستقلة بتنشاف
DocPrism	الحالات يلي عم تنفحص صارت 52/52، بعد ما كانت 26/52
الاختبارات	12 اختبار جديد

7. الخطوة 4: تعليمات الذكاء الاصطناعي

مبنية على **تعليمات DocPrism المنشورة بمستودعهم**: ملخص للتوثيق وملخص للكود، وبعدين ثلاث أسئلة، ولكل جواب "نعم" نسخ حرفي من التوثيق ومن الكود، وبدون أمثلة جاهزة.

السؤال	التصنيف	هل بيتعرض؟
`conflicting` : الكود بيعمل شي مختلف	تناقض مباشر	نعم
`not_implemented` : مذكور وما انعمل	وعد زايد	نعم
`undocumented` : الكود بيعمل شي ما انذكر	وعد ناقص	لأ (متل DocPrism)

إضافاتنا: درجة ثقة لكل نتيجة (من METAMON)، وأرقام الأسطر، وطلب واحد لكل كلاس، وبند للكلاس نفسه للادعاءات العامة. وإذا الكود الأصلي مش متوفر، منعيد بناء الدالة من المعلومات المحفوظة بالخطوة 1.

تصليح انكشف: `### Function: f` إذا إجت بعد قسم كلاس، كانت تضيع. صار يفتّش عليها بالكلاسات التانية.

تجربة حقيقية (طلبين، على مثال برّا بيانات القياس، زرعنا فيه تناقضين): الموديل لقى الاثنين بثقة 1.0، ولقى كمان ادعاء ثالث صحيح ما كان مزروع. والجواب كان JSON صحيح، وكل الجمل المنسوخة موجودة حرفياً بالتوثيق.

8. الخطوة 5: الإرسال والقراءة والفلترة

ملف `doc_semantic_analyzer.py` ، وهو الجزء الثاني من طريقة DocPrism: **الفلترة الخارجية**.

المرحلة	شو بتعمل
الإرسال	لحد 3 محاولات، وإعادة المحاولة ما بتستعمل الجواب المحفوظ. إذا فشل كل شي: ما في crash، والكلاس بينسجّل إنه ما انفحص
الوعد الناقص	بينحفظ بس ما بيتعرض
النسخ من التوثيق	إذا الجملة مش موجودة **بتوثيق هالدالة نفسها**، بتنرمى (اختراع)
النسخ من الكود	إذا الأسطر مش من الكود يلي انعرض، أو السطر المنسوخ مش موجود، بتنرمى
عتبة الثقة	المعروض بس يلي ثقته 0.7 أو أكتر
التكرار	نتيجة وحدة لكل دالة ونوع
الإحصائيات	قديش انرمى ولأي سبب، وقديش انعرض

الاختبارات: 18 اختبار بأجوبة مكتوبة بإيدنا، لحتى ما نصرف من الحد اليومي. **والتجربة الحقيقية:** 3 تنبيهات انعرضت وكلها صحيحة، و 3 وعود ناقصة انخفت، وما انرمى ولا شي على إنه مخترع.

9. الخطوة 6: الربط بالنظام

التغيير	ليش
المحلّل الجديد صار يشتغل تلقائياً بكل مقارنة بين الكود والتوثيق	هاد الهدف
"الكلاس غير موثّق" و "الدالة غير موثّقة" راحوا لإحصائيات التغطية بس	تغطية، مش تناقض
الفحص البسيط للتوقيع انشال	سبب كل إنذارات النظام القديم الوهمية على CASCADE
الفحص الثابت للتوثيق المنظّم ضل، وصار يفهم توقيعات الجافا وما بيقارن نوع غير معروف	دقيق وما بيكلّف شي، وبيضل شغّال إذا الذكاء الاصطناعي فشل
إعدادين: تشغيل وإيقاف الذكاء الاصطناعي، وعتبة الثقة	للتحكم بالتكلفة والدقة
قسم "ميزات جديدة غير موثّقة" بالتحليل الكامل صار ياخد من الإحصائيات	لأنه قائمة المشاكل تغيّرت

مشكلة مهمة انكشفت

قراءة الملفات **ما بتسجّل لغة الملف** بالتحليل أبداً. فكود البايثون كان رح ينبعت للذكاء الاصطناعي كأنه جافا، وأرقام الأسطر رح تطلع غلط، والتنبيهات الصحيحة رح تنرمى. صار النظام يستنتج اللغة من شكل الكود.

الواجهة ما تعدّلت: قائمة المشاكل صار فيها تناقضات حقيقية، وقسم "Undocumented" الموجود أصلاً بيعرض الدوال غير الموثّقة، والألوان ونسبة التغطية متل ما هني.

10. جدول التقدّم على CASCADE

المرحلة	القسم	النظام	انكشف	إنذارات كاذبة	Specificity	PFP	طلبات
الأساس	تطوير	القديم	17/25	17/25	0.32	0.00	0
الأساس	تطوير	الحالي	1/25	1/25	0.96	0.00	0
الأساس	اختبار	القديم	32/46	32/46	0.30	0.00	0
الأساس	اختبار	الحالي	0/46	0/46	1.00	—	0
بعد الخطوة 6 (بدون LLM)	تطوير	الحالي	0/25	**0**	1.00	—	0
بعد الخطوة 6 (بدون LLM)	اختبار	الحالي	0/46	**0**	1.00	—	0

هلق **ولا إنذار كاذب**. والتناقضات لسا ما انكشفت لأنه الذكاء الاصطناعي كان مسكّر بهالقياس، وهاد مقصود. **القياس الحقيقي مع الذكاء الاصطناعي** على قسم التطوير بيحتاج 50 طلب، يعني الحد اليومي كله، فبيكون ببداية يوم جديد.

11. مشاكل انكشفت اليوم

#	المشكلة	الحالة
1	نجاح النظام القديم على CASCADE وهمي (PFP = 0)	موثّق، ورقم للمقارنة
2	الدوال المستقلة ما بتنفحص (بايثون وجافاسكربت وتايبسكربت)	انصلحت (3ب)
3	اسم الدالة مع الأنواع العامة (`useRetry<T>`) ما بينطابق مع التوثيق	انصلحت
4	دالة بالتوثيق بعد قسم كلاس كانت تضيع	انصلحت (4)
5	الفحص البسيط للتوقيع بيعدّ فواصل أمثلة الاستخدام	انشال (6)
6	`_parse_signature` ما بتفهم توقيعات الجافا (`name(..) +`)	انصلحت (6)
7	قراءة الملفات ما بتسجّل لغة الملف	النظام بيستنتجها (6)
8	فرق 70 مقابل 71 ببيانات CASCADE، و 7 حالات مسافاتها مكسورة بـ DocPrism	موثّق ومعالج

12. الحسابات والمفاتيح

- **OpenRouter:** الحساب مجاني (50 طلب باليوم). المفتاح القديم ما كان موجود بحسابكم، فرجع 401 "User not found". **انعمل مفتاح جديد** وهو شغّال.
- **GitHub:** انعمل مفتاح قراءة للمشاريع العامة بس (5000 طلب بالساعة)، لتنزيل كود NPM.
- المفاتيح محفوظة بملف `.env` ، وهالملف مستثنى من git. والمساعد ما بيقرأ المفاتيح، وهاد إجراء أمان.
- **الموديل الثابت للقياس:** `poolside/laguna-s-2.1:free` ، و temperature 0، و seed 42. والأجوبة بتنحفظ وبيعاد استعمالها إذا تكرر نفس الطلب.

13. سجل الـ commits والملفات

commit	الوصف
`65532d0`	بيانات الأوراق، والخطوة 3ب (الدوال المستقلة)، ووثيقة البيانات والمقاييس، وإيميل NPM
`23202b3`	الخطوة 4: تعليمات الذكاء الاصطناعي ومجهّز الطلبات، وتقسيم CASCADE
`a87a00f`	الخطوة 5: الإرسال والقراءة والفلترة
`f9b2099`	الخطوة 6: الربط بالنظام

ملفات جديدة

- `core_ai/services/conflict_detection/` : `doc_prompt_builder.py` و `doc_semantic_analyzer.py`
- `evaluation/paper_sets/` : `build_paper_sets.py` و `fetch_npm_code.py` و `PROGRESS.md` وملفات الوسم
- الاختبارات: `test_module_functions.py` و `test_doc_prompt_builder.py` و `test_doc_semantic_analyzer.py` و `test_code_doc_integration.py` و `conftest.py`
- التقارير: `step3b` و `step4` و `step5` و `step6` بمجلد `core_ai/tests/reports/`

الاختبارات	الصبح	بعد 3ب	بعد 4	بعد 5	بعد 6
العدد (كلهم ناجحين)	44	56	69	87	**97**

14. الخطوات الجاية

1. **أول قياس حقيقي مع الذكاء الاصطناعي** على قسم التطوير من CASCADE (50 طلب، ببداية يوم جديد). منشوف قديش تناقض انكشف، وقديش إنذار كاذب، وقيمة PFP، ومنقارن مع أرقام الورقة.
2. **تحليل الأخطاء** على قسم التطوير، ومنعدّل عتبة الثقة إذا لزم.
3. **قياس قسم الاختبار** (92 طلب، يومين) بالمحطة المهمة.
4. **الكود مقابل الكود (الخطوات 7 لـ 11)** على بيانات NPM، بعد ما يخلص التنزيل.