تقرير التقدّم 2: تقسيم التوثيق وخط القياس

الخطوة 3 (DocSplitter) + مجموعة التطوير + قياس الأساس: القديم مقابل الحالي

التاريخ: 25-10-2026 يكمّل: progress_report_steps_0-2.pdf آخر commit: `2afa9a1`

44/44	66	من 6 لـ 0	0/6
اختبار ناجح بالـ Docker	عنصر موسوم بمجموعة التطوير	إنذارات كاذبة على عناصر سليمة (Code vs Doc)	تغييرات سلوكية انكشفت (بالنسختين)

المحتويات

1. ملخص: شو صار من التقرير السابق
2. الخطوة 3: تقسيم التوثيق (DocSplitter)
3. ليش ضفنا خط قياس هلق
4. مجموعة التطوير: العينات والوسم
5. الموديل المثبّت للقياس
6. سكربت القياس وتعريف المقاييس
7. نتائج Code vs Doc
8. نتائج Code vs Code
9. الخلاصة وشو لازم يتحسن
10. المطلوب من الفريق، والـ commits، والخطوة الجاية

1. ملخص: شو صار من التقرير السابق

الشغل	النتيجة	commit
الخطوة 3: DocSplitter	التوثيق صار ينقسم لأجزاء (ملف، كلاس، دالة) وكل جزء بينربط بعنصره بالكود. الإنذارات الكاذبة على التوثيقات الحقيقية نزلت لصفر.	`9af541b`
خط القياس	مجموعة تطوير فيها 66 عنصر موسوم، وسكربت بيحسب Precision و Recall و F1 للنسختين، وقياس الأساس.	`2afa9a1`

2. الخطوة 3: تقسيم التوثيق (DocSplitter)

2.1 قبل التصميم: فحص التوثيقات الحقيقية

فحصنا 3 توثيقات مولّدة من النظام ومحفوظة بـ MongoDB (كلاس `Book` بالجافا: 2 high-level و 1 low-level). لقينا:

- **الموديل ما بيلتزم بشكل العناوين.** نفس الـ constructor انكتب بثلاث أشكال: `public Book(String title, ...)` و `Book(String title, ...)` و `Book` . ومرة كتب توقيع بايثون (`self`) لكود جافا.
- **في تناقض حقيقي بالأقسام العامة:** التوثيق بيقول "Retrieve the book's title, **author**, and ISBN"، والكود ما فيه `getAuthor` .
- `doc_normalizer.py` موجود بالمشروع بس ما حدا بيستعمله.

2.2 شو بيعمل DocSplitter

الجزء	الوظيفة
`split()`	بيقسّم التوثيق لأجزاء `file` و `class` و `method`. بيفهم `Constructor:` و `Method:` بكل أشكالها، و `## File:` بتوثيق المشروع، والتوثيق المنظّم كقاموس. وإذا ما في عناوين، بيرجع لبحث بأسماء الدوال.
`match()`	بيربط كل جزء بالعنصر المقابل، وبيطلّع 3 قوائم: **انربط** (رح ينبعت للـ LLM)، **بيحكي عن عنصر مش موجود** (مؤشر جديد)، و**عناصر بدون توثيق** (تغطية).
الربط مع الـ checker	الـ checker الحالي صار يستعمل الـ splitter فوق الـ regex القديم (union)، فما بينشال شي كان موثّق.

2.3 النتيجة على التوثيقات الحقيقية

التوثيق	النسخة الأصلية	بعد الخطوتين 1 و 2	بعد الخطوة 3
high-level #1	setAvailable	Book	ولا تنبيه
high-level #2	3 غير موثّقة + setAvailable	3 غير موثّقة + Book	3 غير موثّقة
low-level	ولا تنبيه	Book	ولا تنبيه
تنبيهات غلط	2	3	0

من وين إجت التنبيهات الغلط

- **setAvailable (النسخة الأصلية):** توقيعات الجافا بتبلّش بـ `+`، والدالة `_parse_signature` ما بتفهمها فبتعتبر المعاملات صفر. الخطوة 1 صلّحت هالشي بالصدفة عبر حقل `parameters`.
- **Book (بعد الخطوة 1):** الخطوة 1 خلّت constructors الجافا تظهر، بس الـ regex القديم ما بيعرف `Constructor:`. **خطأ سبّبته الخطوة 1 وانصلح بالخطوة 3.**

الاختبارات: 23 اختبار جديد (منهم 10 أشكال عناوين)، والمجموع 44/44 بالـ Docker. التفاصيل بـ `core_ai/tests/reports/step3_doc_splitter.md`.

3. ليش ضفنا خط قياس هلق

اختبارات الوحدة بتأكد إنه الكود بيشتغل متل ما كتبناه، بس **ما بتقيس إذا النتيجة عم تتحسن**. وشفنا مثال على هالشي: الخطوة 1 خرّبت شي بالكود مقابل التوثيق بدون ما تنتبه أي اختبار وحدة، وما بيّن الخلل إلا لما جرّبنا على توثيقات حقيقية.

لهيك قدّمنا القياس: منقيس النسخة القديمة مرة وحدة، وبعد كل خطوة منقيس الجديد ومنضيف سطر على جدول التقدّم.

المجموعة	الاستعمال	ليش منفصلة
مجموعة التطوير `evaluation/dev_set/`	منقيس عليها بعد كل خطوة لنعرف الاتجاه	صغيرة ونحنا وسمناها، فبتعطي مؤشر بس
مجموعة الاختبار DocPrism و Cascade	بتنقاس مرة وحدة بالآخر للتقرير	إذا ضلّينا نعدّل ونقيس عليها، منفصّل النظام عليها بدون قصد وتطلع الأرقام أحلى من الحقيقة

4. مجموعة التطوير: العينات والوسم

4.1 Code vs Doc: 10 عينات، 46 عنصر

العينة	شكل التوثيق	شو بتختبر
`doc_user_repo`	low-level	Raises KeyError مقابل "validates email"، "return None (Direct)" بدون فحص (Over)، ValueError ما انذكر (Under)
`doc_http_client`	low-level	"Results are cached" بدون cache (Over)، دالة بدون توثيق (skip)
`doc_rectangle_high`	high-level	perimeter بترجّع scale، w×h (Direct) بتعدّل الكائن بدل ما ترجّع جديد (Direct)
`doc_text_utils_docstrings`	docstrings	"Returns None" والكود بيرمي (Direct)، "strip" ما انعمل (Over)، مسح ملف موجود (Under)
`doc_mailer_params`	low-level	القيمة الافتراضية: التوثيق 3، الكود 5 (Direct)
`doc_counter_threadsafe`	low-level	"thread-safe" و "under a lock" بدون أي lock (Over)، على الكلاس والدالة)
`doc_inventory_java`	low-level (Java)	Throws مقابل getOrDefault (Direct)، فحص كمية ما انعمل (Over)
`doc_real_book_high_1` و `_high_2` و `_low`	حقيقية من Mongo	"retrieve author" بدون getAuthor (Over)، على الكلاس)، توثيق مختصر (skip)

Consistent	Direct_Mismatch	Over_Promise	Under_Promise	skip
26	6	8	2	4

4.2 Code vs Code: 17 عينة، 20 عنصر

Q1 Q2 Q3	المعنى	العدد	العينات
1 0 x	بنيوي بس	10	rename، حذف دالة، حذف كلاس، إضافة دالة، parameter اختياري، parameter إجباري، دالة ← property، constructor جافا
1 1 0	**سلوكي بس (الأخطر)**	4	`d[k]` ← `d.get(k,-1)`، strip ← raise ← return None، lower، شيل فحص الرصيد (جافا)
1 1 1	بنيوي + سلوكي	2	timeout=30 ← 5، نوع الإرجاع str ← int
0 0 0	ما في تغيير حقيقي	4	تعليقات بس، sum ← loop، استخراج دالة مساعدة، ternary ← Math.max

Q1: هل تغيّرت الواجهة؟ — Q2: هل تغيّر السلوك لاستدعاء صالح بالنسختين؟ — Q3: هل بينكسر مستدعي قديم؟ (حسب `guide_code_vs_code.md`)

الوسم لسا مسودة

كل الوسم كتبه Claude ومعلّم `draft:claude` ، مع دليل لكل تناقض (العبارة من التوثيق ورقم السطر بالكود، وتأكدنا إنه رقم السطر صح). حسب دليل الوسم، لازم **شخصين من الفريق يراجعوه**.

5. الموديل المثبّت للقياس

- الإنتاج بيستعمل `openrouter/free` ، يلي بيختار موديل مختلف كل مرة، فما بينفع للقياس.
- الموديلات المكتوبة بالمشروع (`llama-3.3-70b:free` وغيرها) **ما عادت موجودة** على OpenRouter.
- جرّبنا 6 موديلات مجانية على حالة "Raises KeyError مقابل return None":

الموديل	النتيجة	الوقت	tokens
`poolside/laguna-s-2.1:free` ✅ **المختار**	Direct_Mismatch	5.2s	186
`cohere/north-mini-code:free` (بديل)	Direct_Mismatch	8.6s	361
`nvidia/nemotron-3.5-lightning:free`	Direct_Mismatch	12.5s	1490
`nvidia/nemotron-3-ultra-550b:free`	Direct_Mismatch	37.0s	873
`google/gemma-4-31b-it:free` و `gemma-4-26b`	429 (مشغول)	—	—
`nvidia/nemotron-3-super-120b:free`	404	—	—

كل الاستدعاءات بتمرق من `llm_recorder` : temperature 0، و seed 42، وبدون cache، وبدون fallback لموديل تاني، وكل رد بينسجّل.

6. سكربت القياس وتعريف المقاييس

`evaluation/harness/evaluate.py` بيشغّل النسختين على نفس العينات، وبيقارن مع الوسم، وبيحفظ النتيجة الخام وسطر بجدول التقدّم. النسخة القديمة بتنحسب مرة وحدة وبتنحفظ لأنها مجمّدة.

المقياس	المعنى
Precision	من كل يلي نبّه عليه النظام، قديش صح؟ (أعلى = إنذارات كاذبة أقل)
Recall	من كل المشاكل الحقيقية، قديش لقى؟
F1	توازن بين الاثنين
Specificity	من كل العناصر السليمة، قديش تركها بحالها؟
Flag Rate	نسبة العناصر يلي نبّه عليها

- **Code vs Doc:** الصح = `Direct_Mismatch` أو `Over_Promise` . أما `Under_Promise` فحسب DocPrism ما بيتعرض للمستخدم.
- **Code vs Code:** كشف التغيير = (Q1 أو Q2)، وكل سؤال بينقاس لحاله.
- **أي تنبيه على عنصر ما إله مشكلة ولا تغيير بينحسب إنذار كاذب.**
- التعريف بيعتمد على **مخرجات النظام بس**، مش على آليته الداخلية.

7. نتائج Code vs Doc

النظام	Precision	Recall	F1	Specificity	Flag Rate	TP	FP	FN	TN
القديم	0.091	0.071	0.080	0.688	0.239	1	10	13	22
الحالي	0.000	0.000	0.000	0.875	0.087	0	4	14	28

الجواب الصح	العدد	نبّه القديم	نبّه الحالي
Direct_Mismatch	6	1	0
Over_Promise	8	0	0
Under_Promise	2	0	0
Consistent	26	6	0
skip (بدون توثيق)	4	4	4

التفسير

1. **ولا نسخة بتكشف تناقضات حقيقية.** من 14 مشكلة، القديم لقى وحدة والحالي ولا وحدة. هاد متوقع، لأنه المسارين ما فيهم أي LLM لسا.
2. **إصابة القديم كانت صدفة:** `Rectangle.scale` انمسكت بسبب "Signature mismatch: 1 vs 0"، وهاد خطأ بقراءة التوقيع. المشكلة الحقيقية إنها بتعدّل الكائن. يعني **العنصر صح والسبب غلط**.
3. **الحالي شال كل الإنذارات الكاذبة على العناصر السليمة (من 6 لـ 0)**: الـ constructors (الخطوة 3) و setAvailable (الخطوة 1).
4. الإنذارات الأربعة الباقية كلها "غير موثّقة". هي تغطية، ورح تنشال بالخطوة 6.

8. نتائج Code vs Code

النظام	Precision	Recall	F1	Specificity	Q1 F1	Q2 F1	Q3 F1	LLM
القديم	0.727	0.500	0.593	0.500	0.762	0.000	0.556	18
الحالي	0.750	0.562	0.643	0.500	0.818	—	0.632	17

"—" يعني الحالي ما ادّعى ولا مرة إنه في تغيير سلوكي. ومن الـ FP بالنسختين، تنبيهين على عناصر ما تغيّرت: `Shelf.size` (إعادة تسمية وهمية) و `Account.limit`.

أخطر نوع تغيير ما عم ينكشف

العنصر	التغيير	القديم	الحالي
`Store.find`	`d[k]` (بترمي) ← `d.get(k, -1)`	فات	فات

`Repo.get`	`raise KeyError` ← `return None`	فات	فات
`Parser._clean`	`strip()` ← `lower()`	فات	فات
`Account.withdraw`	انشال فحص الرصيد	فات	فات
`Conn.connect`	`timeout=30` ← `5`	فات	فات
`Person.full_name`	دالة ← `@property`	فات	فات

السبب: الـ LLM بيشوف التوقيعات بس. الـ body والقيم الافتراضية والـ decorators ما بينبعتوا. وهاد شغل الخطوات 7 لـ 11.

التفسير

1. **الحالي أحسن بشوي (F1 من 0.593 لـ 0.643)** لأنه constructors الجافا صارت تنشاف (الخطوة 1)، فانكشف تغيير الـ constructor تبع `Account`.
2. **القديم كان يسمّي الحذف "تغيير سلوكي":** `legacy_charge` (محذوفة) انحسبت rename لـ `charge` بنوع `behavior_change`. بالحالي النوع صار `renamed` (الخطوة 2)، فاختفى هالخطأ.
3. **إنذارات غلط من الـ LLM:** نبّه على refactor مكافئ (`Invoice.total`)، وقال عن parameter اختياري إنه "required" (`Report.render`).

9. الخلاصة وشو لازم يتحسن

نجح	ناقص	ناقص
تقليل الإنذارات الكاذبة: Specificity بالكود مقابل التوثيق من 0.69 لـ 0.88	كشف التناقضات الحقيقية: Recall = 0 بالكود مقابل التوثيق	كشف التغييرات السلوكية: 0 من 6 بالكود مقابل الكود

المسار	الهدف	الخطوات
Code vs Doc	رفع Recall من الصفر، مع الحفاظ على Specificity ≥ 0.875	4 و 5 و 6
Code vs Code	Q2 Recall أكبر من صفر، وما يطلع إنذار على التغييرات المكافئة الأربعة ولا على `Shelf.size` ، واستدعاءات LLM أقل	7 لـ 11

10. المطلوب من الفريق، والـ commits، والخطوة الجاية

المطلوب من الفريق

- **مراجعة الوسم** بالملفين `labels_code_vs_doc.csv` و `labels_code_vs_code.csv` من شخصين، حسب دليل الوسم.
- حالات بتستاهل نقاش: `Book` ("Over_Promise" ← "retrieve author على مستوى الكلاس)، و `Counter` ("thread-safe" على الكلاس والدالة).

الـ commits

commit	الوصف
`9af541b`	Step 3: DocSplitter + تقرير PDF للخطوات 0–2
`2afa9a1`	Evaluation track: dev set, draft labels, evaluate.py and baseline metrics

الخطوة الجاية: الخطوة 4 (CODE_DOC_PROMPT)

كتابة الـ prompt يلي بيبعت لكل كلاس كود دواله (التوقيع والجسم) مع جزء التوثيق تبع كل دالة، وبيطلب JSON فيه التصنيف ودرجة الثقة والدليل. بعد الخطوة 5 منقيس على مجموعة التطوير، ومنتوقع يطلع Recall الكود مقابل التوثيق من الصفر.